ҮНЭЛГЭЭНИЙ ТАЙЛАН: ЗЭЭЛИЙН DEFAULT ТААМАГЛАЛ

Хичээл: Машины сургалтын алгоритм | Долоо хоног 4: Логистик регресс ба ангиллын үнэлгээ

1. Асуудал ба дата

Энэхүү ажил нь банкны зээлийн default (зээлээ төлж чадахгүй байх) эрсдэлийг таамаглах логистик регрессийн загварыг бүтээх, үнэлэхэд чиглэсэн. Дата нь нийт 4000 бичлэг, 8 шинж (x1–x8) бүхий синтетик өгөгдөл бөгөөд 75% (3000) нь сургалтын, 25% (1000) нь тестийн дата болгон хуваагдсан. Ангийн тэнцвэр нь маш тэнцвэргүй — зөвхөн 7.3% (73 бичлэг) нь default (эерэг), үлдсэн 92.7% нь сайн зээл (сөрөг) байна.

2. Загвар ба сургалт

Загвар нь логистик регресс бөгөөд scikit-learn-ийн Pipeline ашиглан StandardScaler болон LogisticRegression-ийг нэгтгэсэн. Параметрүүд: C=1.0 (regularization-ийг тэнцвэртэй байлгах), max_iter=1000. Шийдвэрийн босгыг 0.5-аас эхлээд 0.35, 0.25, 0.15 хүртэл өөрчлөн, бизнесийн зардлын шинжилгээнд хамгийн тохиромжтой босгыг сонгох зорилготой ажилласан.

3. Үр дүн

Загварын тестийн ROC-AUC үзүүлэлт 0.871 гарсан нь загвар ангиллыг сайн ялгаж чадаж байгааг харуулж байна. Хүснэгтээс харахад Accuracy (нарийвчлал) нь бүх босгон дээр 0.92-0.96 хооронд өндөр байгаа ч, энэ нь тэнцвэргүй датад төөрөгдүүлэхүйц үзүүлэлт юм.

Босго, Precision (Нарийвчлал), Recall (Бүрэн байдал), F1, Нийт зардал (10·FN + FP)

0.50, 0.919, 0.466, 0.618, 393

0.35, 0.830, 0.603, 0.698, -

0.25, 0.701, 0.644, 0.671, -

0.15, 0.486, 0.712, 0.578, 265

Хамгийн чухал 2 тоо:

0.50 босгон дээр Recall нь ердөө 0.466 байгаа нь бодит default-уудын 53%-ийг алдаж байгааг харуулж байна.

0.15 босгон дээр Recall нь 0.712 болж, нийт зардал 265 болж хамгийн багадаа хүрсэн.

4. Шийдвэр

Зардлын шинжилгээгээр (нэг FN = 10 нэгж, нэг FP = 1 нэгж) 0.15 босгыг сонгосон. Учир нь 0.50 босгон дээр зардал 393 байсан бол 0.15 босгон дээр 265 болж буурсан. Энэ нь нэг алдсан default (FN)-ийн зардал нь буруу дохиолол (FP)-оос 10 дахин их тул илүү олон хүнийг шалгах нь банкинд илүү ашигтай гэдгийг харуулж байна.

Дүгнэлт: «0.15 босгон дээр default-ын 71%-ийг барьж байна, нэг алдагдал 10 нэгж гэж үзвэл нийт зардал 265 — хамгийн бага.»

5. Хязгаарлалт

8 шинж нь нэргүй (x1–x8) — бизнесийн утгыг тайлбарлаж чадахгүй. Бодит credit scoring датад эдгээр нь орлого, зээлийн түүх, өрийн харьцаа гэх мэт байх ёстой.

Дата нь зохиомол (синтетик) — make_classification-аар үүсгэсэн тул бодит банкны датад шууд хэрэглэж болохгүй. Бодит датад илүү төвөгтэй хамаарал, дутуу утга, outlier байж болно.

6. Дараагийн алхам

class_weight='balanced' эсвэл SMOTE аргыг туршиж, тэнцвэргүй датаг зохицуулах.

PR-AUC (Precision-Recall AUC)-г тооцоолж, ROC-AUC-тай харьцуулах — тэнцвэргүй датад PR-AUC нь илүү мэдээлэлтэй үзүүлэлт юм.

https://github.com/Biku1108/W4_Machine_Learning.git